


Laboratorio 6: DBSCAN + KDTree


Prof. Rosa Yuliana Gabriela Paccotacya Yanque

rypaccotacya@ucsp.edu.pe

Descripción

Este laboratorio puede ser elaborado en grupos de hasta 2 personas. El objetivo es implementar el algoritmo de DBSCAN clásico y el que usa un KDTree en C++.





Dataset

El grupo debe buscar un dataset que le ayude a verificar la eficiencia de su algoritmo y con el cual puedan realizar una comparación de ambas implementaciones en tiempo de ejecución. Probar por lo menos con 2 datasets: un dataset de 2 dimensiones y otro de más de 4 dimensiones. Para la visualización de más de 3 dimensiones pueden usar una función de reducción de dimensionalidad a 2D: PCA o TSNE o UMAP <https://www.kaggle.com/code/samueltcortinhas/intro-to-pca-t-sne-umap>
 Link de ayuda:

https://scikit-learn.org/stable/auto_examples/cluster/plot_linkage_comparison.html#sphx-glr-auto-examples-cluster-plot-linkage-comparison-py

Entregable:

- 2 archivos: 1 pdf y 1 zip
- Informe explicando los resultados obtenidos, la visualización de clusterización con diferentes hiperparametros y también la comparación de tiempos de ejecución de ambas implementaciones (clasico y KdTree).
- En el informe tambien responder:
 - Indica la complejidad computacional de ambas implementaciones
 - Mide el Silhouette Score (Coeficiente de Silueta) (Puede ser hecho en Python: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html)
 - ¿Cómo se puede estimar un valor inicial razonable para min_samples?
 - ¿Qué estrategias se pueden emplear para optimizar eps y min_samples?

- ¿Cómo influye la "maldición de la dimensionalidad" en la elección y optimización de los hiperparámetros de DBSCAN? ¿Qué estrategias se usan para manejar esto?
- Aunque los KD-Trees son eficientes, ¿existen limitaciones o escenarios donde su ventaja se reduce, especialmente en datasets de muy alta dimensionalidad? ¿Qué alternativas existen?
- Nota: Las visualizaciones pueden ser hechas en otro lenguaje de programación diferente a C++.
- Código en archivo comprimido.
- **Fecha límite de entrega: 18/06/2025 23:59pm**

Evaluación:

- Informe
- Código legible
- Evaluación en clase con nuevo dataset en formato csv, con dimensiones ≥ 2
- Formulario:
- - Traer implementada una función que:
 - Les devuelva cuantos puntos son outliers
 - Gráfica de la clusterización, incluir una función que les pueda reducir la dimensionalidad a 2D, PCA, TSNE, UMAP.
 - Métricas de clustering: Silhouette score